

Gérer les données d'un travail de recherche

JcB

07/03/2015

Contents

0.1	Organiser les fichiers	2
0.2	Note book (code book)	2
0.3	Anatomie d'un tableur	2
0.4	Le format csv	4
1	Les tableurs	4
2	Le cahier de laboratoire ou NoteBook	4
3	Organiser ses données	4
3.1	Cycle de vie des données [3]	4
3.2	Formats de fichier [1]	4
3.3	Nommage des fichiers [1]	5
3.4	Sauvegardez vos données [1]	5
3.5	Sécurisez vos données	5
4	Utiliser un tableur [2]	6
4.1	Anatomie d'une feuille de calcul	6
4.2	Le nom des colonnes (header)	7
4.3	Les pièges à éviter	7
5	NETTOYER LES DONNÉES [5]	7
6	Quand utiliser une démarche quantitative ?	8

Un travail de recherche peut se résumer à l'équation suivante: 'Question de recherche + données + analyse (statistique) + publication Le présent chapitre s'intéresse au point 2 et très partiellement au point 3.

Les étapes de l'analyse statistique:

- statistique descriptive: il s'agit de décrire les données au travers de quelques chiffres qui les résument
- univariée: moyenne, médiane, quantiles
- bivariée: covariance, corrélation, régression, comparaison de deux moyennes
- multivarié: ANOVA
- statistique inférentielle: un travail porte toujours sur un échantillon que l'on espère aussi représentatif d'une population que l'on ne connaîtra probablement jamais. L'inférence rassemble les techniques statistiques qui permettent d'extrapoler les conclusions basées sur un échantillon à une population.

- modélisation

sigma σ, μ, σ^2

Les données (data) sont le corolaire indiscociable de tout travail de recherche. Elle peuvent exister avant de poser la question de recherche (travail rétrospectif) ou apparaitre après que la question soit posée (travail prospectif). La nature et la pertinence des données à recueillir relève de la QR. On s'intéresse ici à la gestion de ces données en vue de leur exploitation statistique. C'est un étape cruciale pour deux raisons:

- 80% du temps nécessaire au traitement des données consiste à les rendre “présentables”, c'est à dire prêtes à être “moulées” par un logiciel de statistique. Plus on est pressé plus cette organisation des données est importante.
- une bonne organisation des données permet à un observateur extérieur de comprendre comment le travail s'est construit et au chercheur de reprendre son travail plusieurs mois ou année plus tard sans se demander comment il a pu obtenir ces résultats. Cette attitude “écologique” connaît un développement important actuellement sous le nom de “reproductible research”. C'est aussi un moyen de contrôler la fraude scientifique.

En pratique il faut disposer de trois outils - un tableur pour saisir les données et faire un premier nettoyage des données. - un logiciel de statistiques pour exploiter les données. - un traitement de texte qui à la manière d'un cahier de laboratoire permettra de conserver une trace de toutes les opérations effectuées sur les données.

0.1 Organiser les fichiers

- un dossier principal portant le titre de l'étude
- 3 sous dossiers:
- **data**
- **notebook**
- **stat**
- **production**

La gestion des données soulève les questions suivantes:

- comment stocker et organiser mes données ?
- comment rendre mes données persistantes ?
- comment partager mes données avec un statisticien?
- comment exploiter statistiquement mes données ?
- comment s'inscrire dans une démarche de recherche reproductible ?

0.2 Note book (code book)

0.3 Anatomie d'un tableur

Les données portent généralement sur des mesures appelées **variables** effectuées sur des **individus**. Les données sont stockées dans un tableau rectangulaire appelé **table** pour une base de données, **feuille** pour un tableur, **matrice** en mathématiques ou **dataframe** en statistiques.

Par convention[5]:

- chaque ligne du tableau représente un individu unique
- chaque colonne contient les différentes valeurs d'une même variable.

- une table ne doit contenir qu'un type de données
- si plusieurs tables sont nécessaires, elles doivent inclure une colonne, identique dans chaque table, qui permette de les lier (merging)

C'est une bonne pratique de regrouper les variables:

- les variables qualitatives (sexe, CSP) appelées aussi **facteurs** qui permettent de faire des analyses par sous groupes
- les variables quantitatives (age, notes) qui serviront aux calculs (moyenne)
- la première ligne du tableau appelée **header** contient le nom des colonnes. Dans certains cas il est possible de réserver les premières lignes du tableau pour y noter des informations à propos des variables ou de l'étude (métadatas). Cependant cette pratique des à déconseiller au profit du document texte associé au tableur (voir le paragraphe notebook)

Ce gabarit doit être bien pensé dès le départ pour éviter toute réorganisation importante par la suite, source d'erreur par confusion des versions.

Règles:

0.3.0.1 Nom de colonnes AgeAuDiagnostic plutôt que ADx ou tout autre abréviation incompréhensible pour une autre personne.

0.3.0.2 les caractères interdits

- les accents
- les blancs: confondus avec les séparateurs de colonne. A remplacer par le caractère *underscore*.
- la virgule: confondue avec les séparateurs de colonne. A remplacer par le point décimal.
- les caractères réservés

0.3.0.3 les autres interdits

- les macros
- la surbrillance ou les couleurs

Astuces

- chercher/remplacer

Petite classification des variables - Toutes les variables - qualitative ou Variable factorielle (sexe, parité) divisées en catégories (levels) mutuellement exclusif - quelconque: sexe, CSP, binaires (fumeur ou non) - ordinales (l'ordre à un sens): échelle de Likert, score de Glasgow - quantitatives: poids, - continue (taille) - discrètes (nombre de frères et soeurs)

- les représenter par des caractères alphabétiques plutôt que par des chiffres: H ou F est plus explicite que 1 ou 2, sans compter le risque de confusion ou d'erreur d'interprétation (calcul de la moyenne sur le sexe)

Les données manquantes

Ne pas mélanger dans une même colonne des lettres et des chiffres.

0.4 Le format csv

Comment faire communiquer un tableur et un logiciel statistique ? CSV = comma separated virgule (données séparées par une virgule Format universel (fichier/enregistrer sous) Les colonne du tableur sont remplacées par des virgules Le nom du fichier se termine par .csv Il existe des variantes (tab,;) [http://fr.wikipedia.org/wiki/Comma-separated_values] Le format csv ne connait pas les formats multifeuilles (classeurs). chaque feuillet du classeur devra être enregistré séparément.

1 Les tableurs

Le tableur doit servir à recueillir les données et rien d'autre.

2 Le cahier de laboratoire ou NoteBook

3 Organiser ses données

Votre travail de recherche est important et des données bien organisées faciliteront le travail du statisticien et de vos pairs qui doivent pouvoir reproduire et évaluer vos résultats (ref[1]).

3.1 Cycle de vie des données [3]

- données brutes (raw data)
- données désorganisées (messy data)
- donnée nettoyées et exploitables (tidy data)

Carly Strasser et coll.[3] décrivent 8 composants 1. planifier 2. collecter: les données sont recueillies à la main ou récupérées via des capteurs et stockées sur un support numérique 3. Vérifier la qualité et l'intégrité des données 4. Décrire: les données sont soigneusement et précisément décrites sous forme de métadonnées standardisées 5. Préserver: les données placées sur un support permettant de les stocker sur le long terme 6. Découvrir: les données potentiellement utiles sont localisées et obtenues avec les métadonnées qui les accompagnent. 7. intégrer: les données provenant de sources disparates sont combinées pour former un ensemble de données homogènes qui puisse être analysé 8. Analyser: analyse des données

3.2 Formats de fichier [1]

Certains formats de fichiers sont plus adaptés à la conservation que d'autres. Par exemple, certains formats sont propriétaires, ce qui signifie que leur structure ne est pas accessible au public pour la documentation ou la réplication. Si vous enregistrez vos données dans un tel format et que la société qui le détient cesse d'exister, il peut être impossible de les récupérer. Idéalement les données:

- doivent rester accessibles dans le futur (20 ans)
- dans un format non propriétaire
- respecter des standards ouverts, documentés
- être commun, utilisé par la communauté de recherche pertinent ou des communautés;
- utiliser des polices de caractère ouvertes et standard (ASCII, Unicode);
- ne pas dépendre d'un support unique pour être affichées ou manipulées.
- si possible ni cryptées, ni compressées.

Les standards ouverts sont par exemple:

- texte: ASCII ou Unicode (UTF8)
- Pour l'audio: MPEG-4, pas Quicktime;
- Pour les images: TIFF ou JPEG2000 ou PNG, (pas GIF ou JPG)
- Pour données structurées: XML, JSON ou RDF (pas SGBDR)
- traitement de texte: libre office (pas Word)
- tableur: libre office (pas excel)

3.3 Nommage des fichiers [1]

Le nom donné aux fichiers est très important car c'est par cet identifiant que les données sont lues par un logiciel statistique et que l'on peut savoir si la version utilisée est la bonne. Certaines disciplines ont défini des standard très élaborés ([DOE's Atmospheric Radiation Measurement \(ARM\) program](#)).

Voici quelques recommandations:

- Utilisez un système de nommage des fichiers qui reste cohérent.
- la lecture du nom doit être suffisamment explicite pour rester compréhensible durant plusieurs années. Par exemple: projet_questionnaire_lieu_date_version.ext
- Évitez ces symboles dans les noms de fichiers: “/ : *? “<> [] & \$. Ces caractères ont une signification particulière dans certains systèmes d'exploitation d'ordinateur qui pourrait entraîner une mauvaise lecture ou la suppression de ces fichiers.
- évitez les caractères accentués qui sont mal supportés par les logiciels statistiques
- Utilisez le caractère soulignement (_), pas des espaces pour séparer les termes.
- Essayez de garder les noms de dossiers courts (15-20 caractères ou moins) et descriptif de ce qui est à l'intérieur.
- Essayez de garder les noms de fichiers de moins de 25 caractères.
- Inclure les dates dans les noms de fichiers ou de dossiers; utiliser le format AAAA-MM-JJ.
- Si vous ne utilisez pas le versionnage automatique, inclure un numéro de version à la fin du nom de fichier tel que v01. Changez ce numéro de version chaque fois que le fichier est enregistré. Ne utilisez pas d'étiquettes confusion: la révision, finale, final2, etc.
- Pour la version finale, remplacer le dernier mot pour le numéro de version. (Ceci est particulièrement important si les fichiers sont partagés.)
- Les noms de fichiers doivent contenir qu'un seul point, avant l'extension de fichier (par exemple name_paper.doc PAS name.paper.doc)

3.4 Sauvegardez vos données [1]

Il est généralement conseillé de faire trois copies de vos données. Par exemple, vous pourriez avoir le jeu original, une copie sur un disque dur externe local, et une autre copie sur un disque externe situé ailleurs. Ces copies doivent avoir des localisations géographiques différentes. Assurez-vous que le système de back-up est fiable et que les données sont réellement récupérables. Le “Cloud” est une solution envisageable (Google drive, Bit Bucked).

3.5 Sécurisez vos données

En général le cryptage des données n'est pas conseillé. Cependant il peut être indispensable pour certaines données sensibles (données nominatives, personnelles, recommandation de la CNIL) de les crypter. Gardez des mots de passe et les clés sur le papier (2 exemplaires), et dans un fichier numérique crypté comme PGP (Pretty Good Privacy). Ne comptez pas sur le cryptage 3ème partie seul.

Il est également recommandé de stocker des données dans un format non compressé. Si vous avez besoin d'économiser de l'espace, nous recommandons de limiter la compression à votre copie de sauvegarde.

4 Utiliser un tableur [2]

Les données sont généralement conservées sur 2 types de support, les tableurs et les bases de données. Il est aisé de passer de l'un à l'autre. Le tableur est la solution universellement adoptée du fait de sa disponibilité immédiate et de son utilisation intuitive. Cependant un certain nombre de règles doivent être respectées.

La première (et très importante): un tableur doit servir à saisir des données et ne servir qu'à cela. La plupart des ennuis commencent lorsqu'on pense qu'un tableur peut tout faire, en particulier des statistiques. Il faut abandonner cette idée et se placer uniquement sous l'angle de la saisie des données. Pour faire des statistiques, il y a des logiciels pour cela.

4.1 Anatomie d'une feuille de calcul

L'organisation des données dans une feuille de calcul pour qu'elle puissent être traitées immédiatement par logiciel de statistiques est une opération semée d'embûches, si on ne respecte pas quelques règles de base.

Métadata

header

individu

variable

	A	B	C	D	E	F	G
1	titre						
2	Objectif(s)						
3	Investigateur						
4	Institution	CESU 67					
5							
6	unité	AS	Date de	DEC	Note	Pre	Post
7	expérimental	IDE	naissance	TRAD	globale	test	test
8		AMB					
9							
10	ID	METIER	AGE	GROUPE	NOTE	PT	OT
11	1	DE	22	DEC	10	5	5
12	2	DE	25	DEC	8	5	6
13	3	DE	23	DEC	7	5	5
14	4	DE	31	DEC	8	4	5
15	5	S	20	DEC	7	3	5
16	6	S	21	TRAD	9	5	8
17	7	S	24	TRAD	10	8	8
18	8	S	25	TRAD	10	7	7
19	9	MB	28	TRAD	5	5	4
20	10	MB	30	TRAD	6	4	4
21							

Une feuille est constituée de **cellules** délimitées par des **lignes** et des **colonnes** formant un tableau rectangulaire où:

- chaque colonne ne doit contenir qu'une et une seule variable.
- chaque ligne ne concerne qu'une et une seule observation
- le total des lignes doit être égal au total des observations + 1 (header)

La conséquence immédiate de la règle 2 est que les données ne doivent pas être groupées.

La feuille de saisie est divisée en 3 zones horizontales:

- la première, **facultative**, sert à stocker les métadonnées [<http://fr.wikipedia.org/wiki/M%C3%A9tadonn%C3%A9e>]. Sa présence est à éviter (utiliser un document annexe) et sera éliminée au moment de l'analyse.
- la seconde stocke le nom des colonnes: c'est l'**en-tête** ou **header**.
- la troisième contient les données proprement dites.

La troisième zone est divisée verticalement en 2:

- les colonnes les plus à gauche contiennent les variables de type “facteur” (factorielles: profession, type de pédagogie)
- les colonnes les plus à droite contiennent les mesures

Métadonnées [A Gentle Introduction to Metadata](#) Jeff Good University of California, Berkeley. Accédé le 28/4/2015 ce sont des données à propos des données. Elles servent à comprendre le contexte dans lequel se fait l'étude:

- nom de l'auteur, des investigateurs
- version du questionnaire
- méthodes de description des variables: ‘pour la rubrique sexe préciser H ou F’.

En pratique il est recommandé de ne pas faire figurer cette zone dans le tableur mais de les faire figurer dans un document annexe comme le **dictionnaire** pour la description des données et le **notebook** pour expliquer comment les données ont été recueillies, par qui, dans quelles conditions, etc.

4.2 Le nom des colonnes (header)

- une seule ligne. Sert à stocker le nom opérationnel des colonnes. Règles: le nom est succinct (5 caractères) il ne doit pas contenir d'espace ou de caractères qui pourrait être mal interprété (, ; / @ &) remplacer les espace par des underscore (caractère 8) : Ceci_est_un_exemple pas de caractères accentués Encodage : UTF-8 Ne pas fusionner les cellules

4.3 Les pièges à éviter

5 NETTOYER LES DONNÉES [5]

Il n'y a que dans les ouvrages de statistique où l'on trouve des données prêtes à être analysées. Dans un travail de recherche les données passent par plusieurs états avant de pouvoir être analysées:

1. les données brutes (raw data): c'est la saisie initiale de l'expérimentateur. Il manque souvent le header, certains type de données sont erronés, erreur de catégorisation des données, caractère mal encodé ou inconnu (caractères accentués, réservés), etc. La lecture directe de ces données par un logiciel de statistique échoue.
2. les données techniquement correctes: ce sont des données brutes corrigées de sorte qu'elle sont techniquement acceptables par un programme de traitement. Les “dirty data” sont transformées en “messy data” (données propres):
 - données manquantes: il manque toujours des données... Chaque fois que c'est possible essayer de retrouver la donnée. Si la donnée est irrécupérable, la remplacer par un symbole compréhensible par le logiciel statistique comme NA (Not Available). Ne jamais laisser une case vide. Eviter les symboles qui prêtent à confusion: 0, 99999, -1, etc. Ne pas confondre NA et Inconnu ou NSP (ne sais pas) ou NSPR (ne souhaite pas répondre). Ne pas supprimer des observations parceque des données manquantes.

- données spéciales: concernent surtout les valeurs numériques pour les nombres n'appartenant pas à l'ensemble des réels: NA, NaN (not a number), Inf.
- données extrêmes (outliers)

3. Données cohérentes: dans cette dernière étape on vérifie la cohérence des données techniquement correctes. Par exemple qu'il n'existe pas d'âge négatif ou supérieur à une certaine limite, une pathologie incompatible avec un sexe donné. Cette étape peut se révéler particulièrement fastidieuse et complexe.

Ce n'est qu'à la fin de cette troisième étape que les données peuvent être soumises à une analyse statistique.

2 remarques: - ces trois étapes doivent faire l'objet de trois fichiers distincts afin de pouvoir revenir en arrière en cas de problème. - toutes les étapes doivent être documentées pour comprendre quelles manipulations ou transformations ont été nécessaires pour passer de l'une à l'autre

6 Quand utiliser une démarche quantitative ?

La recherche qualitative s'intéresse aux données mesurables sur lesquels on peut appliquer des méthodes statistiques pour les décrire, les comparer, les inférer (Tirer une conclusion d'une proposition ou d'un fait, etc. [wikitionnaire](#)) ou les modéliser.

inférence: estimer les paramètres d'une population à partir d'un échantillon. La précision de l'estimation dépend de la taille de l'échantillon. Inversement, si on fixe la précision souhaitée on peut déterminer la taille l'échantillon. D'une manière générale, pour doubler la précision (cad diviser par 2 l'intervalle dans lequel se trouve le paramètre d'intérêt), il faut quadrupler la taille de l'échantillon.

modélisation: c'est trouver la meilleure combinaison possible de plusieurs variables pour prédire le comportement d'une variable d'intérêt. Par exemple quelle sont les chances qu'une personne se plaignant d'une douleur thoracique soit porteuse d'une pathologie coronarienne sachant que l'on a mesuré chez elle un certain nombre de variables (sexe, âge, poids, taux de cholestérol, etc.) dont on a montré préalablement (par les méthodes statistiques précédentes) qu'elles avaient un lien avec la pathologie suspectée. Il existe de nombreuses techniques de modélisation. L'une des plus répandue est le modèle linéaire.